Архиватор на базе алгоритма Хаффмана

Кочанов Андрей Иванович

Группа: *25.Б43-мм*
Кафедра: *системного программирования*
Научный руководитель: *Литвинов Юрий Викторович*
Номер семестра практики: *2*

1. Введение

Данная работа выполнена в рамках учебной практики. Алгоритм Хаффмана — один из наиболее известных алгоритмов сжатия данных без потерь, основанный на понятии «префиксных кодов» — битовых последовательностей, обладающих тем свойством, что код каждого символа не является префиксом кода никакого другого символа. Это позволяет при прочтении битовой последовательности однозначно восстанавливать символы по их битовым кодам. Работа носит учебный характер и направлена на освоение приёмов работы с динамическими структурами данных, битовыми операциями и модульным проектированием на языке C, что делает её полезной для освоения низкоуровневых возможностей языка C.

2. Постановка задачи

Целью работы является получение практического опыта разработки программного обеспечения на примере задачи реализации архиватора на базе алгоритма Хаффмана, а также измерение эффективности сжатия и скорость работы.

Для достижения цели требуется решить следующие задачи:

1. Выполнить обзор существующих реализаций алгоритма Хаффмана.
2. Спроектировать архитектуру консольного приложения.
3. Реализовать консольное приложение.
4. Выполнить тестирование и эксперименты.

3. Обзор

Алгоритм Хаффмана предложен Д. Хаффманом в 1952 году [1]. Идея состоит в построении бинарного дерева, листья которого соответствуют символам алфавита, а путь от корня до листа задаёт префиксный код: часто встречающимся символам достаются короткие коды, редким — длинные. Алгоритм жадно объединяет два узла с наименьшими частотами, поэтому дерево строится за $O(n \log n)$ при использовании очереди с приоритетом. Алгоритм Хаффмана гарантирует построение кода с минимально возможной средней длиной для заданного распределения частот при условии, что каждый символ кодируется отдельным кодовым словом [2].

Канонические коды Хаффмана. В классическом алгоритме Хаффмана декодер должен знать структуру дерева: чтобы понять, какой символ закодирован очередной последовательностью бит, ему нужно двигаться по дереву от корня, пока не достигнет листа. Если передавать дерево целиком, файл становится больше, потому что на каждый узел нужно хранить указатели на потомков. Для того, чтобы передать декодеру меньше информации, достаточно передать длины кодовых слов каждого символа. А сами коды можно восстановить по длинам по строго определённому правилу. Такие коды, восстанавливаемые по фиксированному правилу, называются каноническими. Такие коды применяются, например, в форматах DEFLATE, JPEG и MP3.

В качестве ориентиров рассмотрены открытые реализации на языке C:

- SmnTin/huffman-archiver [3]: реализация на C с каноническими кодами Хаффмана, оптимизированная для больших файлов; демонстрирует высокую пропускную способность.
- MichaelDipperstein/huffman [4]: простая ANSI C реализация с классическими и каноническими кодами.

Вывод из обзора Анализ этих реализаций позволил выделить общие архитектурные решения. Из huffman-archiver SmnTin [3] заимствована идея буферизации битового вывода: биты накапливаются в байте и записываются блоками, что ускоряет работу с потоком. Из учебной реализации MichaelDipperstein [4] — подход к построению дерева через очередь с приоритетом и сериализации таблицы частот в заголовок.

4. Описание предлагаемого решения

4.1. Архитектура

- `bitReader`, `bitWriter` — побитовое чтение и запись с внутренним байтовым буфером;
- `bitIO` — сериализация целых чисел в формате little-endian;
- `minHeap` — очередь с приоритетом на бинарной куче;
- `huffmanTree` — узел дерева и построение дерева по таблице частот;
- `prefCodeTable` — ленивая таблица префиксных кодов;
- `huffman` — публичный интерфейс функций сжатия и разжатия файлов

Код разделён на модули по принципу единственной ответственности. Такое разделение позволяет тестировать компоненты изолированно и локализует изменения: замена структуры данных или формата заголовка затрагивает один модуль, не распространяясь на остальные. Альтернатива в виде монолитного файла дала бы небольшой выигрыш по скорости за счёт инлайнинга, но существенно усложнила бы отладку и покрытие тестами.

4.2. Технологии

- Язык C99, компилятор GCC 16 (также собирается Clang и MSVC).
- Система сборки: CMake ≥ 3.25.
- Статический анализ: clang-format (WebKit), clang-tidy.
- CI через GitHub Actions: сборка, проверка форматирования, линтинг, интеграционные тесты на Linux.

4.3. Технические детали

- **Инкапсуляция.** Определения структур вынесены в `.c`-файлы, в заголовках оставлены только непрозрачные объявления. Доступ к полям — исключительно через функции-аксессоры. Это соответствует принципу единственной ответственности и исключает связывание модулей через детали реализации.
- **Ленивая таблица кодов.** Код символа вычисляется при первом обращении к нему и кэшируется в таблице. Повторные обращения к тому же символу не пересчитывают код: при первом появлении символа стоимость — $O(n)$ (n — длина кода), при последующих — $O(1)$. Это даёт выигрыш на файлах с большим числом повторяющихся символов и не требует предварительного обхода всего дерева.
- **Заголовок.** Формат файла: 8 байт исходного размера, 2 байта числа уникальных символов, далее для каждого символа — 1 байт значения и 8 байт частоты; после заголовка — битовый поток. Разрежённая запись частот (только ненулевых) снижает накладные расходы с 2 КБ до десятков–сотен байт.
- **Особые случаи.** Пустой файл — записывается только заголовок. Файл с единственным уникальным символом — ни одного бита данных, при распаковке символ повторяется нужное число раз.
- **Коды ошибок.** Вместо одного значения -1 используется перечисление `HuffmanResult` с разными кодами для «не удалось открыть входной файл», «не удалось создать выходной файл», «ошибка памяти», «ошибка чтения», «ошибка записи», «некорректный формат». Это позволяет вызывающей стороне различать ситуации без парсинга `stderr`.

5. Эксперименты

Для оценки эффективности алгоритма были поставлены эксперименты, измеряющие степень сжатия, время сжатия и время распаковки на разных типах и размерах данных. Использованы пять категорий: повторяющиеся текстовые (repeat, .txt), обычные текстовые (text, .txt), случайные байты (random, .bin), уже сжатые архивы (archive, .zip) и изображения в формате JPEG (photo, .jpg). Для каждой категории — 10 прогонов с расчётом математического ожидания (μ) и среднеквадратичного отклонения (σ).

- Компилятор: gcc версии 16.2.1
- Флаги компиляции: -O3 -DNDEBUG
- Процессор: AMD Ryzen 5 3500U, 1,4–3,7 ГГц
- Оперативная память: 8 ГиБ
- Операционная система: EndeavourOS, ядро Linux 7.x

Таблица 1: Экономия размера, % от исходного размера

Тип	1 КБ	10 КБ	100 КБ	1 МБ	5 МБ
repeat	98.14	99.81	99.98	99.99	99.99
text	10.64	41.86	44.95	45.26	45.29
archive	−216.02	26.37	41.47	52.83	54.07
random	−222.66	−22.56	−2.26	−0.22	−0.04
photo	−190.24	−21.24	−1.99	8.65	0.01

Таблица 2: Время сжатия, мс ($\mu \pm \sigma$, 10 прогонов)

Тип	1 КБ	10 КБ	100 КБ	1 МБ	5 МБ
repeat	1.63 ± 0.45	1.44 ± 0.28	2.56 ± 0.81	8.76 ± 1.36	37.52 ± 3.39
text	1.85 ± 0.49	2.66 ± 0.72	11.21 ± 3.43	77.78 ± 4.48	372.82 ± 6.79
archive	1.67 ± 0.18	2.69 ± 0.77	9.16 ± 1.72	50.92 ± 3.26	240.96 ± 14.47
random	2.14 ± 0.58	3.41 ± 0.87	15.97 ± 4.35	120.68 ± 3.90	579.23 ± 6.58
photo	1.76 ± 0.33	5.06 ± 1.28	15.25 ± 3.53	122.82 ± 4.81	625.19 ± 19.84

Таблица 3: Время распаковки, мс ($\mu \pm \sigma$, 10 прогонов)

Тип	1 КБ	10 КБ	100 КБ	1 МБ	5 МБ
repeat	1.58 ± 0.31	1.30 ± 0.12	2.77 ± 0.88	11.91 ± 3.03	50.85 ± 6.63
text	1.89 ± 0.48	2.95 ± 0.94	10.45 ± 1.79	84.39 ± 4.48	404.91 ± 6.63
archive	1.87 ± 0.45	3.19 ± 0.57	9.48 ± 2.41	55.37 ± 3.69	251.26 ± 7.26
random	1.84 ± 0.30	3.12 ± 0.73	17.48 ± 4.05	133.38 ± 4.94	638.79 ± 6.81
photo	1.56 ± 0.11	5.05 ± 1.38	15.87 ± 2.06	136.32 ± 4.51	672.20 ± 12.27

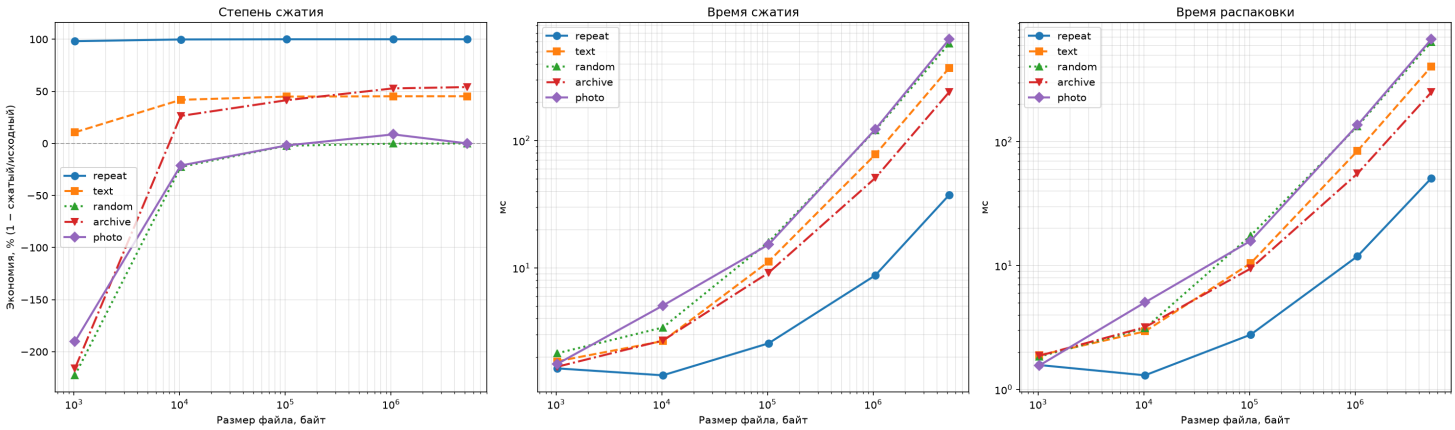


Рис. 1: Зависимость степени сжатия и времени работы от размера файла

5.1. Выводы из результатов эксперимента

- Эффективность сжатия определяется энтропией входных данных и размером алфавита. Однородные данные (`repeat`) сжимаются почти идеально: при одном уникальном символе код занимает 0 бит, сжатый файл для всех размеров равен 19 байтам (только заголовок), экономия — от 98.1% на 1 КБ до 99.99% на 5 МБ. Текст сжимается на 42–45% для размеров от 100 КБ; на 1 КБ — всего 10.6% из-за накладных расходов на заголовок ($8+2+9k$ байт, где k — число уникальных символов). Архивы ZIP дают 26–54% экономии, поскольку в наборе данных они содержат текст и служебные заголовки.

- На случайных данных и JPEG-изображениях алгоритм неэффективен: на 1 КБ размер вырастает на 190–222% из-за доминирующего заголовка, а на 5 МБ практически не меняется (-0.04% для `random`, $+0.01\%$ для `photo`). Это ожидаемо: обе категории уже имеют высокую энтропию, и префиксный код не может их сжать.

- Время работы асимптотически линейно зависит от размера входного файла ($O(n)$): и сжатие, и распаковка выполняются за один проход по данным. При увеличении размера с 1 КБ до 5 МБ (в 5000 раз) время сжатия выросло в 20–350 раз в зависимости от типа данных: наименьший рост у `repeat` ($\approx 23\times$), наибольший — у случайных и сжатых данных (`photo`: $\approx 355\times$).

- Разброс времени (σ) для крупных файлов составляет 1–5% от μ, что говорит о стабильности измерений. На 1–10 КБ стабильность ниже: относительный вклад операций открытия файла, выделения памяти и системных вызовов становится заметнее.

- Самыми медленными оказались случайные данные и фотографии: из-за 256 уникальных символов средняя длина кода приближается к 8 битам, поэтому на каждый байт входа приходится выполнять почти столько же побитовых операций, сколько занимал сам байт, и экономии не происходит.

6. Заключение

В ходе выполнения работы получены следующие результаты:

- изучена теория префиксных кодов и алгоритма Хаффмана, включая канонические коды;

- реализован модульный консольный архиватор на C с инкапсулированными структурами данных, ленивой таблицей префиксных кодов и явной обработкой ошибок;

- построена система интеграционных тестов, покрывающая полный цикл «сжатие — распаковка» для текстовых, вырожденных и пустых файлов;

- проведены эксперименты по измерению степени сжатия и времени работы на данных пяти типов; сформулированы выводы о применимости алгоритма.

Репозиторий/ссылка на пуллреквест: `https://github.com/Andrew-Kochanov/archiverHuffman`.
Техническая документация: `https://github.com/Andrew-Kochanov/archiverHuffman/blob/main/README.md`.

Список литературы

1. Huffman D. A. A Method for the Construction of Minimum-Redundancy Codes // Proceedings of the IRE. — 1952. — Vol. 40, No. 9. — P. 1098–1101.

2. Cormen T. H., Leiserson C. E., Rivest R. L., Stein C. Introduction to Algorithms. — 3rd ed. — MIT Press, 2009. — Ch. 16.3.

3. SmnTin. huffman-archiver [Электронный ресурс]. — URL: `https://github.com/SmnTin/huffman-archiver` (дата обращения: 08.10.2026).

4. MichaelDipperstein. huffman: Huffman code discussion and implementation [Электронный ресурс]. — URL: `https://github.com/MichaelDipperstein/huffman` (дата обращения: 08.10.2026).